

邓鑫宇

✉ husdengsh@gmail.com · ☎ 13458601548 · 🌐 catDforD · 🌐 catdfd.com

🎓 教育背景

浙江大学 杭州	2025 - 至今
电子信息 硕士（在读）	
西南交通大学 成都	2021 - 2025
电子信息 学士	

</> 开源项目

AstrBot SDK 核心开发	2026.05 - 2026.06
Python 插件开发框架 github.com/united-pooh/astrbot-sdk	

- 实现插件初始化时生成 Agent 开发技能与项目说明，配套测试，为 AI 编码提供仓库规范与上下文。
- 参与 HTTP 方法注册与能力路由，完善消息历史和路由校验，同步更新协议、运行时测试与文档。
- 保留请求作用域的系统事件覆盖信息，贯通上下文、代理与分发层，避免请求信息在传递过程中丢失。

AstrBot 开源贡献者	2026.02 - 至今
Agent 平台与开发框架 主仓库个人 PR: catDforD	

- 修复定时任务唤醒 Agent 时未保留备用模型配置的问题，为 Ollama 接入增加关闭思考模式的开关。
- 修复侧边栏分组展开与状态持久化，统一插件界面提示，改善知识库上传错误反馈，通过 GitHub PR 参与已有代码库协作。

🏢 实习经历

晶泰科技 未来化学部实习·深圳	2026.03 - 2026.06
ChemSec-Eval: 化学研发场景的大模型与 Agent 安全评测、护栏加固 成果展示	

- 搭建 Python / Inspect AI 评测框架与批量数据生成工具，覆盖内容、Agent 工具和多轮隐私安全；结合 LLM-as-a-judge、规则回退与异常分类形成可复用评测流程。
- 开发 XCurve 的 OpenAI-compatible 适配服务，配套接口测试与文档，使业务 Agent 接入统一评测。
- 集成知识检索、多轮隐私规则、会话状态和响应扫描，形成可独立集成的组合护栏；以会话 ID 累积风险，缺少 ID 时隔离请求，避免跨会话污染。
- 项目最终评测中，内容 / Agent / 隐私攻击成功率分别由 34.8% / 58.7% / 68.9% 降至 4.4% / 6.1% / 4.7%。

🧠 多智能体研究

MAS ² 多智能体系统研究	2024 - 2025
参与多智能体系统自动生成、配置与执行时纠错研究；论文录用于 ICLR 2026。	

⚙️ 技术实践

Python 工程：HTTP API、协议校验、业务接口适配、测试与文档、Git / GitHub 开源协作。

Agent 相关：SDK 与请求上下文、项目开发指引、模型服务接入、Inspect AI 评测及会话级护栏。