

邓鑫宇

✉ husdengsh@gmail.com · ☎ 13458601548 · 🌐 catDforD · 🌐 catdfd.com

🎓 教育背景

浙江大学 控制科学与工程学院 电子信息 硕士 2025 - 至今
• 推免研究生 研究方向: LLM Agent、Multi-Agent Systems

西南交通大学 电气工程学院 电子信息 学士 2021 - 2025
• GPA: 3.84/4.0 专业排名: 1/36 英语水平: CET-4: 572 CET-6: 552

📁 实习经历

晶泰科技 未来化学部实习 · 深圳 2026.03 - 2026.06

ChemSec-Eval: 化学研发场景的大模型与 Agent 安全评测、护栏加固 [查看成果](#) ↗

- 基于 Inspect AI 搭建化学场景安全评测链路，覆盖内容、Agent 工具和多轮隐私；开发单/批量数据生成与 LLM-as-a-judge 评分，保留规则回退和异常分类，支持模型与业务 Agent 接入。
- 开发 XCurve 的 OpenAI-compatible 适配服务和接口测试，保留多轮消息、会话隔离与 SSE 工具 trace，使业务 Agent 可复用 Inspect 评测流程。
- 集成化学风险知识检索、会话级隐私累积与响应扫描，封装可独立接入的组合护栏；业务 Agent 接入护栏后，三类攻击成功率由 34.8%、58.7%、68.9% 降至 4.4%、6.1%、4.7%，护栏覆盖率为 94.3%。

DeePX / 小π: 晶泰 AI Agent 挑战赛冠军 · Morrow Agent Core [项目展示](#) ↗

- 利用 Morrow Agent 核心完成比赛 Agent 的云端编排与调控，接入飞书 / lark-cli、定时触发与 WebSocket 流式输出，支撑桌面 AI 伙伴的主动提醒和实时交互。
- 重构 Agent 调用链，将 StackChan 与 lark-cli 之间的交互由 6 跳收敛至 4 跳，并以 Morrow 统一编排 OpenClaw 与插件调用，完成日程/消息、Askflow 与飞书审批闭环演示。
- 负责云端部署、Agent 核心接入与运行调控；团队以 DeepX · 晶曜队参赛并获得赛事第一名，个人贡献聚焦 Agent runtime 与实时链路。

</> 开源项目

Morrow 开发与维护 2026.05 - 至今

- 基于 Rust 开发 CLI / Web 编码 Agent，将执行循环与模型、工具适配解耦，两端复用统一运行时，支持流式响应及 MCP 工具接入。
- 实现会话持久化与按 token 预算触发的上下文压缩，以追加式事实日志重建会话状态；压缩模型可见历史的同时保留执行记录，支持历史恢复与会话续接。
- 实现探索、规划、执行、审查四类子 Agent 的调度与权限约束，通过同会话内的共享写入许可协调主 Agent 与执行类子 Agent 的文件修改和 Shell 操作。
- 接入执行前权限审批与验收 Hook，支持将检查反馈回传模型继续处理；构建脚本化模型与工具的回归评测，覆盖工具结果回灌、审批和异常路径，并约束调用次数。

PI-Desktop 5.2k+ 开源贡献者 2026.09 - 至今

- 为桌面 Agent Runtime 补齐 SYSTEM.md / APPEND_SYSTEM.md 支持，处理项目级优先级、提示词组装顺序与配置变更后的会话级重建，并补充运行时与启动链路测试。
- 修复文件/文件夹选择器重复弹窗，在 Renderer 与 Electron Main IPC 双侧增加并发保护；将 AI 设置下拉项改为应用内菜单，统一主题与键盘交互，并补充回归测试。

</> 开源项目（续）

AstrBot 40.8k★ 开源贡献者 2026.02 - 至今

- 修复定时任务唤醒 Agent 时未保留备用模型配置的问题，为 Ollama 接入增加关闭思考模式的开关。
- 修复侧边栏分组展开与状态持久化，统一插件界面提示，改善知识库上传错误反馈。

AstrBot SDK 核心开发 2026.05 - 2026.06

- 修复请求级系统事件覆盖信息的跨层传递丢失问题，并补充回归测试。
- 在插件初始化时生成 Agent 开发指引与项目说明，为 AI 编程提供规范与上下文。

🏠 科研经历

RouterTamperBench 恶意 LLM 路由器安全基准 • USENIX 2027 在投 2026 - 至今

- 设计跨协议评测链路，将请求、工具定义 / 结果、工具调用和最终回答统一为 canonical semantic object，桥接 OpenAI Responses、Chat Completions 与 Anthropic Messages，覆盖流式 SSE。
- 构建可复现数据集流水线与双阶段 tamper runtime，覆盖 143 个任务、43 种变体、939 个案例、13 类攻击族；支持参数/身份替换、结果篡改、调用插入/删除/重放，记录投递、执行、影响与恢复。
- 参与 5 个 Agent、6 个模型、3 种 API 格式组成的 30 种配置实验与结果分析，测得平均攻击成功率 31.9%；789 个可比传播案例中，下游无独立可信参照时成功率 84.1%，具备时 6.0%。

MAS² 多智能体系统研究 • ICLR 2026 • 论文链接 2024 - 2025

- 参与 MAS² 多智能体系统研究，负责实验设计与结果分析；围绕 Generator、Implementer、Rectifier 三类角色，验证架构生成、配置与执行反馈纠错闭环。
- 参与多任务、多模型实验与泛化评估；实验显示，深度研究、代码生成等场景相对先进 MAS 最高提升 19.6%，在未见过的模型骨干上仍有最高 15.1% 提升，录用 ICLR 2026 (Poster)。

⚙️ 技术能力

工程开发： Rust / Python 异步与并发、SSE / WebSocket 流式链路、回归测试与 GitHub CI。

Agent 系统： 工具调用编排、MCP 集成、上下文压缩、会话持久化、多智能体调度与权限审批。

系统架构： 事件驱动、插件化设计、跨协议适配与运行时解耦。

安全评测： LLM-as-a-judge、对抗攻击评测、数据集构建、知识检索与隐私护栏。

开发协作： Claude Code / Codex、OpenSpec、Git / GitHub 协作。