

邓鑫宇

husdengsh@gmail.com · 13458601548 · catDforD · catdfd.com

教育背景

- 浙江大学** 控制科学与工程学院 电子信息 硕士 2025 - 至今
- 推免研究生 研究方向: LLM Agent、Multi-Agent Systems
- 西南交通大学** 电气工程学院 电子信息 学士 2021 - 2025
- GPA: 3.84/4.0 专业排名: 1/36 英语水平: CET-4: 572 CET-6: 552

实习经历

- 晶泰科技** 未来化学部实习 · 深圳 2026.03 - 2026.06
- ChemSec-Eval: 化学研发场景的大模型与 Agent 安全评测、护栏加固 成果展示
- 基于 Inspect AI 搭建化学场景安全评测链路, 覆盖内容、Agent 工具和多轮隐私; 开发单/批量数据生成与 LLM-as-a-judge 评分, 保留规则回退和异常分类, 支持模型与业务 Agent 接入。
 - 开发 XCurve 的 OpenAI-compatible 适配服务和接口测试, 保留多轮消息、会话隔离与 SSE 工具 trace, 使业务 Agent 可复用 Inspect 评测流程。
 - 集成化学风险知识检索、会话级隐私累积与响应扫描, 封装可独立接入的组合护栏; 最终评测中三类攻击成功率由 34.8%、58.7%、68.9% 降至 4.4%、6.1%、4.7%, 护栏覆盖率为 94.3%。

DeePX / 小π: 晶泰 AI Agent 挑战赛冠军 · Morrow Agent 接入

- 利用 Morrow (Rust) Agent 核心完成比赛 Agent 的云端编排与调控, 接入飞书 / lark-cli、定时触发与 WebSocket 流式输出, 支撑桌面 AI 伙伴的主动提醒和实时交互。
- 重构 Agent 调用链, 将 StackChan 与 lark-cli 之间的交互由 6 跳收敛至 4 跳, 并以 Morrow 统一编排 OpenClaw 与插件调用, 完成日程/消息、Askflow 与飞书审批闭环演示。
- 负责云端部署、Agent 核心接入与运行调控; 团队以 DeePX · 晶曜队参赛并获得赛事第一名, 个人贡献聚焦 Agent runtime 与实时链路。

开源项目

- Morrow** 开发与维护 2026.05 - 至今
- 基于 Rust 开发 CLI / Web 编码 Agent, 将执行循环与模型、工具适配解耦, 两端复用统一运行时, 支持流式响应及 MCP 工具接入。
 - 实现会话持久化与按 token 预算触发的上下文压缩, 以追加式事实日志重建会话状态; 压缩模型可见历史的同时保留执行记录, 支持历史恢复与会话续接。
 - 实现探索、规划、执行、审查四类子 Agent 的调度与权限约束, 通过同会话内的共享写入许可协调主 Agent 与执行类子 Agent 的文件修改和 Shell 操作。
 - 接入执行前权限审批与验收 Hook, 支持将检查反馈回传模型继续处理; 构建脚本化模型与工具的回归评测, 覆盖工具结果回灌、审批和异常路径, 并约束调用次数。

- PI-Desktop** 开源贡献者 · 3 个 PR 已合并 2026.09 - 至今
- 为桌面 Agent Runtime 补齐 SYSTEM.md / APPEND_SYSTEM.md 支持, 处理项目级优先级、提示词组装顺序与配置变更后的会话级重建, 并补充运行时与启动链路测试。
 - 修复文件/文件夹选择器重复弹窗, 在 Renderer 与 Electron Main IPC 双侧增加并发保护; 将 AI 设置下拉项改为应用内菜单, 统一主题与键盘交互, 并补充回归测试。

- AstrBot** 开源贡献者 2026.02 - 至今
- 修复定时任务唤醒 Agent 时未保留备用模型配置的问题, 为 Ollama 接入增加关闭思考模式的开关。
 - 修复侧边栏分组展开与状态持久化, 统一插件界面提示, 改善知识库上传错误反馈。

- 修复请求级系统事件覆盖信息的跨层传递丢失问题，并补充回归测试。
- 在插件初始化时生成 Agent 开发指引与项目说明，为 AI 编程提供规范与上下文。

科研经历

RouterTamperBench 恶意 LLM 路由器安全基准 · USENIX 2027 在投

2026 - 至今

- 设计跨协议评测链路，将请求、工具定义 / 结果、工具调用和最终回答统一为 canonical semantic object，桥接 OpenAI Responses、Chat Completions 与 Anthropic Messages，覆盖流式 SSE。
- 构建可复现数据集流水线与双阶段 tamper runtime，覆盖 143 个任务、43 种变体、939 个案例、13 类攻击族；支持参数/身份替换、结果篡改、调用插入/删除/重放，记录投递、执行、影响与恢复。
- 参与 5 个 Agent、6 个模型、3 种 API 格式组成的 30 种配置实验与结果分析；稿件报告平均攻击成功率 31.9%，无可信外部校验时传播率 84.1%，加入校验后为 6.0%。

MAS² 多智能体系统研究 · ICLR 2026 · 论文链接

2024 - 2025

- 参与 MAS² 多智能体系统研究，负责实验设计与结果分析；围绕 Generator、Implementer、Rectifier 三类角色，验证架构生成、配置与执行反馈纠错闭环。
- 参与多任务、多模型实验与泛化评估；论文报告复杂场景最高 19.6% 性能提升、跨模型骨干最高 15.1% 泛化提升，录用 ICLR 2026 (Poster)。

技术实践

工程开发：Python / Rust，异步编程、HTTP API、SSE / WebSocket、自动化测试与 GitHub CI。
Agent 开发：工具调用编排、MCP 集成、上下文压缩、会话持久化、多智能体调度与权限审批。
安全评测：canonical 语义对象、TamperSpec、攻击 taxonomy、可信状态 oracle、可复现 release。
AI 协作开发：Claude Code / Codex、OpenSpec 规范驱动开发、Git / GitHub 协作。