

邓鑫宇

husdengsh@gmail.com · 13458601548 · catDforD · catdfd.com

教育背景

浙江大学 杭州	2025 - 至今
电子信息 硕士 (在读)	
西南交通大学 成都	2021 - 2025
电子信息 学士	

开源项目

Morrow 开发与维护	2026.05 - 至今
- 基于 Rust 开发 CLI / Web 编码 Agent，将执行循环与模型、工具适配解耦，两端复用统一运行时，支持流式响应及 MCP 工具接入。 - 实现会话持久化与按 token 预算触发的上下文压缩，以追加式事实日志重建会话状态；压缩模型可见历史的同时保留执行记录，支持历史恢复与会话续接。 - 实现探索、规划、执行、审查四类子 Agent 的调度与权限约束，通过同会话内的共享写入许可协调主 Agent 与执行类子 Agent 的文件修改和 Shell 操作。 - 接入执行前权限审批与验收 Hook，支持将检查反馈回传模型继续处理；构建脚本化模型与工具的回归评测，覆盖工具结果回灌、审批和异常路径，并约束调用次数。	
AstrBot 开源贡献者	2026.02 - 至今
- 修复定时任务唤醒 Agent 时未保留备用模型配置的问题，为 Ollama 接入增加关闭思考模式的开关。 - 修复侧边栏分组展开与状态持久化，统一插件界面提示，改善知识库上传错误反馈。	
AstrBot SDK 核心开发	2026.05 - 2026.06
- 修复请求级系统事件覆盖信息的跨层传递丢失问题，并补充回归测试。 - 在插件初始化时生成 Agent 开发指引与项目说明，为 AI 编程提供规范与上下文。	

实习经历

晶泰科技 未来化学部实习 · 深圳	2026.03 - 2026.06
ChemSec-Eval: 化学研发场景的大模型与 Agent 安全评测、护栏加固 成果展示	
- 基于 Inspect AI 搭建化学场景安全评测链路，覆盖内容、Agent 工具和多轮隐私；开发单/批量数据生成与 LLM-as-a-judge 评分，保留规则回退和异常分类，支持模型与业务 Agent 接入。 - 开发 XCurve 的 OpenAI-compatible 适配服务和接口测试，保留多轮消息、会话隔离与 SSE 工具 trace，使业务 Agent 可复用 Inspect 评测流程。 - 集成化学风险知识检索、会话级隐私累积与响应扫描，封装可独立接入的组合护栏；最终评测中三类攻击成功率由 34.8%、58.7%、68.9% 降至 4.4%、6.1%、4.7%，护栏覆盖率为 94.3%。	
DeePX / 小π 晶泰内部 AI Agent 全员进化挑战赛 · 晶曜队 · 赛事第一名	2026.06 - 2026.07
Morrow Agent 核心接入 · 云端部署与调控 Agent 分支	
- 利用 Morrow (Rust) Agent 核心完成比赛 Agent 的云端编排与调控，接入飞书 / lark-cli、定时触发与 WebSocket 流式输出，支撑桌面 AI 伙伴的主动提醒和实时交互。 - 将 StackChan → OpenClaw → lark-cli → Plugin → OpenClaw → StackChan 的 6 跳链路收敛为 StackChan → Morrow → lark-cli → Morrow → StackChan 4 跳链路，完成日程 / 消息、Askflow 与飞书审批等业务闭环演示。 - 负责云端部署、Agent 核心接入与运行调控；团队以 DeePX · 晶曜队参赛并获得赛事第一名，个人贡献聚焦 Agent runtime 与实时链路。	

科研经历

RouterTamperBench 恶意 LLM 路由器安全基准 · USENIX 2027 在投

2026 - 至今

The Middleman Lies: Measuring Malicious LLM Router Attacks on Agents 源码

- 设计并实现跨协议的端到端评测链路：将请求、工具定义 / 结果、工具调用和最终回答抽象为 canonical semantic object，桥接 OpenAI Responses、Chat Completions 与 Anthropic Messages，覆盖流式 SSE。
- 构建可复现的数据集流水线与冻结 release，完成攻击 taxonomy、候选枚举、验证去重、选择和物化；投稿稿覆盖 143 个任务、43 种变体、939 个案例，其中 914 个 active cases 覆盖 13 类攻击族。
- 实现请求 / 响应双阶段 tamper runtime 与可信影响 oracle，支持工具参数 / 身份替换、结果篡改、调用插入 / 删除 / 重放及隐蔽变体；用 Agent、MCP 工具和任务环境记录区分投递、执行、影响与恢复。
- 参与跨配置实验与结果分析；投稿稿在 5 个 Agent、6 个模型、3 种 API 格式组成的 30 种配置上报告平均攻击成功率 31.9%，无可信外部校验时传播率 84.1%，加入校验后为 6.0%。
- 投稿稿进一步报告：加入第二次篡改后，隐藏性最多增加 40.0 个百分点、恢复率最多下降 26.3 个百分点；端到端消息认证的覆盖分析将攻击成功率预计降至 6.5%。

MAS² 多智能体系统研究

2024 - 2025

- 参与 MAS² 多智能体系统研究，负责实验设计工作；系统通过 Generator、Implementer、Rectifier 完成架构生成与执行反馈纠错。相关论文发表于 ICLR 2026。 [论文链接](#)

技术实践

工程开发：Python / Rust，异步编程、HTTP API、SSE / WebSocket、自动化测试与 GitHub CI。

Agent 开发：工具调用编排、MCP 集成、上下文压缩、会话持久化、多智能体调度与权限审批。

安全评测：canonical 语义对象、TamperSpec、攻击 taxonomy、可信状态 oracle、可复现 release。

AI 协作开发：Claude Code / Codex、OpenSpec 规范驱动开发、Git / GitHub 协作。